



Analisis Suhu Rata - rata harian Singapura

Muhammad Khaira Rahmadya Nauval
23/521078/TK/57466

Polikarpus Arya Pradhanika
23/512404/TK/56325

Definisi Masalah

Projek Machine Learning yang kami buat mengangkat tema SDG-13, yaitu “Climate Change and It’s Impact” dengan melihat dari sudut perubahan rata-rata suhu harian di Singapura.

Objektif

- Memprediksi suhu rata-rata harian di Singapura kedepannya
- Dapat mengambil konklusi apakah terdapat perubahan signifikan pada suhu rata-rata harian

Dataset

Dataset yang kami gunakan berisi data dengan label berikut:

```
• data.info()
✓ 0.0s

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2859 entries, 0 to 2858
Data columns (total 11 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   date                                  2859 non-null   object
1   station                              2859 non-null   object
2   daily_rainfall_total                 2859 non-null   object
3   highest_30_min_rainfall              2859 non-null   object
4   highest_60_min_rainfall              2859 non-null   object
5   highest_120_min_rainfall             2859 non-null   object
6   mean_temperature                    2859 non-null   object
7   maximum_temperature                 2859 non-null   object
8   minimum_temperature                 2859 non-null   object
9   mean_wind_speed                     2859 non-null   object
10  max_wind_speed                      2859 non-null   object
dtypes: object(11)
memory usage: 245.8+ KB
```

Sumber

<https://data.gov.sg/datasets?query=Historical+Daily+Weather+Records>

Data Exploration

Dengan menggunakan “data.head()”, ditemukan bahwa banyak *value* ‘na’ tapi tidak terbaca sebagai data dengan *null value* oleh Python.

Perlu adanya konversi *value* ‘na’ menjadi *null value* yang bisa dibaca Python

```
data.replace('na', np.nan, inplace=True)
print(data.isnull().sum())
```

```
date           0
station        0
daily_rainfall_total    105
highest_30_min_rainfall 1755
highest_60_min_rainfall 1755
highest_120_min_rainfall 1755
mean_temperature    139
maximum_temperature  115
minimum_temperature  115
mean_wind_speed     96
max_wind_speed      97
dtype: int64
```

Data Exploration

Ditemukan pula bahwa tipe data dari dataset yang dipakai masih belum sesuai, maka perlu adanya konversi tipe data.

```
date          object
station       object
daily_rainfall_total  object
highest_30_min_rainfall  object
highest_60_min_rainfall  object
highest_120_min_rainfall object
mean_temperature  object
maximum_temperature object
minimum_temperature object
mean_wind_speed   object
max_wind_speed    object
dtype: object
```

Data Exploration

Untuk konversi tipe data, kami mencocokkan dengan tipe data yang tertera di website.

```
# Karena datatype masih tidak cocok, maka diconvert sesuai yang tertulis di website
for col in data.columns:
    if col == 'date':
        data['date'] = pd.to_datetime(data['date'], format='%Y-%m-%d', errors='coerce')
    elif col == 'station':
        data['station'] = data['station'].astype(str)
    else:
        data[col] = pd.to_numeric(data[col], errors='coerce')
```

```
date                datetime64[ns]
station             object
daily_rainfall_total float64
highest_30_min_rainfall float64
highest_60_min_rainfall float64
highest_120_min_rainfall float64
mean_temperature    float64
maximum_temperature float64
minimum_temperature float64
mean_wind_speed     float64
max_wind_speed      float64
dtype: object
```

Data Cleaning (Hapus Kolom)

Terdapat beberapa langkah yang dilakukan untuk membersihkan data, sebagai berikut:

- Menghapus kolom untuk kolom dengan missing values terlalu besar

```
removed_columns = ['highest_30_min_rainfall', 'highest_60_min_rainfall', 'highest_120_min_rainfall']  
data_clean = data.drop(columns=removed_columns)  
data_clean.head()
```

✓ 0.0s

	date	station	daily_rainfall_total	mean_temperature	maximum_temperature	minimum_temperature	mean_wind_speed	max_wind_speed
0	2009-01-01	Admiralty	NaN	NaN	NaN	NaN	NaN	NaN
1	2009-01-02	Admiralty	NaN	NaN	NaN	NaN	NaN	NaN
2	2009-01-03	Admiralty	NaN	NaN	NaN	NaN	NaN	NaN
3	2009-01-04	Admiralty	NaN	NaN	NaN	NaN	NaN	NaN
4	2009-01-05	Admiralty	NaN	NaN	NaN	NaN	NaN	NaN

Data Cleaning (Interpolasi)

- Melakukan interpolasi terhadap beberapa missing values

```
numerical_columns = data_clean.select_dtypes(include=[np.number]).columns.tolist()
data_clean[numerical_columns] = data_clean[numerical_columns].interpolate(method='linear', order=3)
data_clean.isnull().sum()
```

✓ 0.0s

date	0
station	0
daily_rainfall_total	21
mean_temperature	23
maximum_temperature	21
minimum_temperature	21
mean_wind_speed	21
max_wind_speed	21
dtype: int64	

Data Cleaning (Hapus Baris)

- Menghapus baris - baris tersisa yang masih bernilai null

```
# Hapus baris di awal dan akhir yang memiliki nilai null  
data_clean = data_clean.dropna()  
data_clean.isnull().sum()
```

✓ 0.0s

```
date          0  
station       0  
daily_rainfall_total  0  
mean_temperature  0  
maximum_temperature  0  
minimum_temperature  0  
mean_wind_speed  0  
max_wind_speed  0  
dtype: int64
```

Data Cleaning (Menghapus Outliers)

- Menghapus Outliers karena dapat merusak performa model

```
# Menghapus outliers menggunakan metode IQR
Q1 = data_clean[numerical_columns].quantile(0.25)
Q3 = data_clean[numerical_columns].quantile(0.75)
IQR = Q3 - Q1

# Menentukan batas bawah dan atas
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

# Menyaring data untuk menghapus outliers
data_clean = data_clean[~((data_clean[numerical_columns] < lower_bound)
|| (data_clean[numerical_columns] > upper_bound)).any(axis=1)]
```

Membangun Model

Data yang digunakan adalah time series dan kita akan melakukan prediksi terhadap nilai tertentu, untuk itu kita akan menggunakan metode regresi dalam membuat model

Mempersiapkan data (*split* data menjadi data latih dan uji)

- data latih ~**80%** total dataset
- data uji ~**20%** total dataset

```
final_data = data_clean.drop(['date', 'station'], axis=1) # Drop non-numeric columns for regression
X_train, y_train, X_test, y_test = split_data(final_data, target="mean_temperature", test_size=0.2) #
✓ 0.0s
```

Parameter dan Target

Parameter yang akan dimasukkan ke model (X) adalah

- daily_rainfall_total
- maximum_temperature
- minimum_temperature
- mean_wind_speed
- max_wind_speed

Parameter target yang akan diprediksi (y) adalah

- mean_temperature

Menguji Model

Model akan dievaluasi performanya dengan 3 matriks evaluasi yaitu

R^2 (Koefisien Determinasi)

- Mengukur seberapa baik variabel independen menjelaskan variasi dari variabel dependen.

MSE (Mean Squared Error)

- Menghitung rata-rata kuadrat dari selisih antara nilai prediksi dan nilai aktual.

MAE (Mean Absolute Error)

- Mengukur rata-rata nilai absolut dari selisih prediksi dan nilai aktual.


Model 1 - Regresi Linear

Data Latih

- $R^2 = 0.7937$
- $MSE = 0.2627$
- $MAE = 0.3998$

Data Uji

- $R^2 = 0.7288$
- $MSE = 0.2698$
- $MAE = 0.3940$




Model 2 - Polinomial Orde 2

Data Latih

- $R^2 = 0.8182$
- $MSE = 0.2315$
- $MAE = 0.3710$

Data Uji

- $R^2 = 0.7343$
- $MSE = 0.2643$
- $MAE = 0.3887$




Model 3 - Polinomial Orde 3

Data Latih

- $R^2 = 0.8303$
- $MSE = 0.2161$
- $MAE = 0.3559$

Data Uji

- $R^2 = 0.7269$
- $MSE = 0.2717$
- $MAE = 0.3894$



Pemilihan Model


Terlihat bahwa model **Polinomial Orde 2** memiliki hasil evaluasi yang lebih baik dari Regresi Linear.

Namun model **Polinomial Orde 3** tidak memberikan hasil yang lebih baik pada data latih meskipun memberikan hasil sedikit lebih baik pada data uji.

Sehingga, kita akan memilih model **Polinomial Orde 2** untuk model Machine Learning kita

Evaluasi Model - Walk Forward

Karena data adalah *time series*, maka validasi dapat dilakukan dengan *Walk Forward Cross Validation*. Dilakukan dengan membagi data menjadi beberapa *window* dan melakukan validasi terhadap setiap *window*.



Evaluasi Model - Walk Forward

Parameter yang digunakan:

- ukuran data latih per window = **400**
- ukuran data uji per window = **100**

Hasil pengujian mendapatkan hasil:

- Mean R2 : **0.6883**
- Mean MAE : **0.4109**
- Mean MSE : **0.2810**

Ini menunjukkan bahwa model Polinomial Orde 2 **cukup stabil** untuk mengatasi keseluruhan data

Prediksi Data Baru

Berikut adalah contoh prediksi data baru dengan parameter tertentu

- daily_rainfall_total: **0.0**
- maximum_temperature: **31.4**
- minimum_temperature: **24.4**
- mean_wind_speed: **11.7**
- max_wind_speed: **38.2**

Hasil Prediksi

- Mean Temperature: **27.065735**

Kesimpulan

- Suhu rata - rata harian di Singapura memiliki hubungan Polinomial Orde 2 yang cukup kuat dengan parameter - parameter kondisi cuaca lainnya.
- Berdasarkan hasil prediksi model yang telah dilakukan, tidak terdapat fluktuasi suhu yang signifikan terhadap pola musiman yang terjadi di Singapura. Hal ini menunjukkan tidak terdapat perubahan iklim yang signifikan di Singapura.
- Hasil validasi dengan Walk Forward Cross Validation menunjukkan bahwa model memiliki kestabilan yang baik terhadap keseluruhan data

Referensi

- Fahad, Istiaq Ahmed. "Understanding Walk Forward Validation in Time Series Analysis: A Practical Guide." Medium, 28 Okt. 2024, <https://medium.com/@ahmedfahad04/understanding-walk-forward-validation-in-time-series-analysis-a-practical-guide-ea3814015abf>. Diakses pada 5 Apr. 2025.
- National Environment Agency. "Historical Daily Weather Records." data.gov.sg, 2024, https://data.gov.sg/datasets/d_03bb2eb67ad645d0188342fa74ad7066/view. Diakses pada 5 Apr. 2025.